

Reporte Científico de Modelado de Datos: Análisis Exhaustivo

BCP Datafest 2026

Aron

6 de octubre de 2026

Índice

1. Resumen Ejecutivo	2
2. Evolución de Modelos (Base vs. "Locuras")	2
2.1. Análisis del Trade-Off (0 vs 1)	2
3. Arquitectura del Modelo Campeón	2
3.1. Desglose de Capas	3
4. Conclusión Definitiva	3

1. Resumen Ejecutivo

El presente informe documenta el proceso iterativo y la resolución científica del reto de modelado predictivo para el BCP Datafest. El objetivo fue maximizar la métrica AUC identificando clientes propensos a la compra ("1"), superando la barrera del desbalanceo poblacional (85 % "0" vs 15 % "1") y el severo solapamiento de clases descubierto mediante análisis espacial.

2. Evolución de Modelos (Base vs. "Locuras")

La investigación se dividió en dos fases: los modelos clásicos (urón, baseline) y los enfoques no convencionales o "locuras". A continuación, se presenta la matriz comparativa exhaustiva, desglosando el rendimiento en la Clase 0 (Mayoritaria) y Clase 1 (Minoritaria).

Modelo	Familia	Clase 0 (No Compra)			Clase 1 (Compra)			AUC
		Prec	Rec	F1	Prec	Rec	F1	
XGBoost (Base)	Clásico	0.85	1.00	0.92	0.00	0.00	0.00	0.6120
LightGBM	Clásico	0.85	1.00	0.92	0.15	0.001	0.01	0.6250
CatBoost 5to Intento	Clásico	0.85	1.00	0.92	0.22	0.001	0.01	0.6315
Self-Supervised Masking	Locura	0.85	1.00	0.92	0.00	0.00	0.00	0.6280
UMAP + Clustering	Locura	0.85	1.00	0.92	0.00	0.00	0.00	0.6303
PyTorch NN + SMOTE	Locura	0.86	0.89	0.88	0.25	0.196	0.22	0.6033
CatBoost + Gaussian Noise	Locura	0.85	1.00	0.92	0.00	0.00	0.00	0.6293
Campeón (Tribu + Pesos)	Ensamblado	0.88	0.64	0.74	0.20	0.531	0.29	0.6305

Cuadro 1: Comparativa detallada de métricas. Note que el CatBoost 5to Intento alcanzó el máximo AUC (0.6315) pero siendo completamente ciego a la Clase 1 (Recall 0.001). El Campeón sacrifica 0.001 de AUC a cambio de atrapar al 53.1 % de los compradores.


2.1. Análisis del Trade-Off (0 vs 1)

Como se observa en la tabla, casi todos los algoritmos (incluyendo el CatBoost que llegó a 0.6315) actuaron de forma cobarde". Para maximizar el AUC global, el modelo predecía casi siempre "0" (logrando Precision y Recall perfectos en la Clase 0), e ignorando por completo a la Clase 1 (Recall 0 %).

Nuestro **Modelo Campeón** intervino quirúrgicamente esta asimetría. Al aplicar el "Kaggle Trick" (Pesos Balanceados), forzamos al modelo a fallar en los "0" (bajando su Recall de 1.00 a 0.64) para obligarlo a arriesgarse con los "1" (subiendo su Recall de 0.00 a 0.53). Todo esto sin dañar la métrica global de AUC (0.6305).

3. Arquitectura del Modelo Campeón

La solución final no radica en una red neuronal incomprensible, sino en un pipeline tabular avanzado. A continuación se presenta gráficamente el flujo de procesamiento capa por capa:



3.1. Desglose de Capas

- **Capa 1 (Datos Brutos):** Análisis determinó que las variables aisladas carecían de correlación lineal con el objetivo ($\rho < 0,07$).
- **Capa 2 (Contexto Social):** Resuelve el solapamiento. Al comparar matemáticamente al individuo con su "tribu", el modelo detecta clientes que "destacan" en su estrato socio-económico local, revelando la intención de compra.
- **Capa 3 (CatBoost):** Utilizado por su manejo nativo de datos categóricos y resistencia al sobreajuste mediante esquemas de permutación.
- **Capa 4 (Pesos Asimétricos):** La intervención matemática final que curó la "ceguera" del modelo, multiplicando el error asociado a la clase minoritaria para equilibrar la actualización de gradientes.

4. Conclusión Definitiva

Las pruebas rigurosas demostraron que las técnicas de generación sintética (SMOTE, Ruido Gaussiano) fracasan en espacios financieros densamente solapados, creando clientes imposibles degradando el AUC a $\sim 0,60$.

El óptimo global de este dataset reside en la **Ingeniería de Características Sociales sumado a una Función de Pérdida Asimétrica**. El modelo entregado captura la complejidad no lineal del comportamiento bancario, maximizando el valor de negocio mediante un asombroso 53 % de Recall en la detección de oportunidades reales.