

Reporte Científico de Modelado de Datos: Análisis Exhaustivo y Arquitectura Ganadora

BCP Datafest 2026

Aron

7 de octubre de 2026

Índice

1. Resumen Ejecutivo	2
2. Evolución y Rompimiento del Límite de 0.63 AUC	2
3. Arquitectura del Modelo Ganador (Customer Propensity Pipeline)	2
3.1. Desglose de Componentes Clave	3
4. Conclusión Definitiva	3

1. Resumen Ejecutivo

El presente informe documenta el proceso científico del reto de modelado predictivo para el BCP Datafest. Inicialmente, el proyecto se enfrentó a un techo de cristal predictivo insuperable en **0.63 AUC**. Sin embargo, tras 23 experimentos (Locuras), el análisis reveló que el error no radicaba en la matemática, sino en el planteamiento del problema: los datos no eran transacciones estáticas, sino registros temporales longitudinales (Panel Data). Al rediseñar la arquitectura para evaluar la historia financiera completa del cliente, el modelo rompió el techo histórico, logrando un récord robusto de **0.86 AUC**.

2. Evolución y Rompimiento del Límite de 0.63 AUC

Durante los primeros 20 intentos, se aplicaron técnicas de frontera (Cleanlab, SMOTE, Redes Neuronales, Undersampling Espacial, XGBoost). El máximo histórico fue 0.6367. Se determinó que evaluar filas de forma independiente generaba colisión en el espacio muestral y un severo "Data Leakage" durante la validación cruzada.


El cambio de paradigma en el **Intento 23** comprimió 110,100 registros mensuales en **24,628 "Biografías" de Clientes únicos**, extrayendo toda su volatilidad y tendencia histórica.

Modelo	Paradigma	Clase 0 (No Compra)			Clase 1 (Compra)			AUC
		Prec	Rec	F1	Prec	Rec	F1	
XGBoost (Baseline)	Transaccional Estático	0.85	1.00	0.92	0.00	0.00	0.00	0.6120
CatBoost + SMOTE	Transaccional Sintético	0.86	0.89	0.88	0.25	0.196	0.22	0.6033
CatBoost + Contexto Social	Transaccional Relativo	0.88	0.64	0.74	0.20	0.531	0.29	0.6305
Panel Data Base	Longitudinal	0.70	0.65	0.67	0.80	0.78	0.79	0.8020
Campeón (CatBoost + SHAP)	Longitudinal + Poda	0.60	0.77	0.68	0.87	0.75	0.80	0.8627

Cuadro 1: Comparativa Histórica. El salto de 0.63 a 0.86 AUC ocurre exclusivamente al agrupar los datos por cliente y extraer agregaciones matemáticas, capturando un increíble 75 % de Recall positivo con alta precisión (0.87).

3. Arquitectura del Modelo Ganador (Customer Propensity Pipeline)

La solución ganadora abandona la predicción estática mensual para adoptar una **Agregación Longitudinal** complementada con un **Bisturí de Explicabilidad (SHAP)**.



3.1. Desglose de Componentes Clave

- **Agregación Temporal:** Al agrupar los datos de un cliente a través de los meses y extraer su volatilidad (σ) y sus tendencias (Δ), logramos entregarle al algoritmo la *película financiera* del cliente, no solo su foto final.
- **SHAP Pruning:** Crear métricas a destajo genera inevitablemente ruido matemático. Usar los valores SHAP en el conjunto de entrenamiento para destruir las 25 variables irrelevantes permitió al CatBoost enfocar toda la entropía en señales puras y predictivas.
- **Cross-Validation Estricto:** Para asegurar que el 0.86 AUC no fuera un golpe de suerte o *overfitting*, el modelo superó pruebas de estrés con 4 particiones aleatorias independientes (splits estratificados 90/10 y 80/20). El modelo promedió **0.856 AUC** demostrando robustez universal.

3.2. Detalle Quirúrgico: Variables Retenidas y Eliminadas

El éxito de esta arquitectura dependió de la poda exacta de las variables. De las 74 generadas originalmente, el análisis SHAP determinó la eliminación absoluta de las siguientes 25 variables que solo aportaban ruido:

- **Varianzas inútiles eliminadas:** edad_std, distancia_sucursal_km_std, visitas_web_ultimos_90_dia, numero_productos_std. (La edad o la distancia a la sucursal no varían lógicamente en meses, por lo que su desviación estándar era puro ruido matemático).
- **Variables estáticas o irrelevantes eliminadas:** tiene_seguro, es_nuevo_cliente, dia_preferido_pago (en todas sus agregaciones: mean, min, max, std).

- **Tendencias ruidosas:** `ingresos_trend`, `ratio_deuda_ingresos_trend`, `saldo_promedio_trend`. Sorprendentemente, la delta simple final no aportaba valor comparado con las agregaciones estadísticas de las mismas.

El Núcleo de Élite (49 Variables): El modelo retuvo las 49 variables más determinantes, enfocándose principalmente en:

1. **Estado Final Categórico:** `banda_riesgo`, `region`, `ocupacion`.
2. **Momentos Estadísticos Clave:** Los picos máximos y promedios del `saldo_promedio` y del `ratio_deuda_ingresos`.
3. **Comportamiento Transaccional:** `dias_ultima_interaccion` y `meses_en_sistema`.

4. Conclusión Definitiva

El problema principal nunca fue algorítmico, sino de modelado conceptual. Al refactorizar el dataset para evaluar "Personas" en lugar de "Transacciones", y al podar la basura matemática con Teoría de Juegos, logramos saltar de un techo estancado del 63 % a un modelo comercialmente impecable de 86 % de Área bajo la Curva.

El código fuente compilado reside en `pipeline_final.py`.